

线性回归模型的矩阵表示法

- 最小二乘法（最小平方法）是基于误差为高斯分布（正态）的假设来的。
- 在用线性回归做预测时，或多或少存在误差，因此引入误差变量epsilon，将误差看作是随机变量。
- 根据大数定理，样本数增多，误差会慢慢服从正态分布。

假设epsilon服从正态分布，针对每个样本得出条件概率：

线性回归的误差模型

$$y = w^T x + b + \epsilon \quad \epsilon \sim N(0, \sigma^2)$$

针对于样本 (x_i, y_i)

$$p(y_i | x_i) \sim N(w^T x_i + b, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(w^T x_i + b - y_i)^2}{2\sigma^2}}$$

高斯噪声模型根据最大似然估计法求参数w,b: (优化最小二乘)

基于所有样本的最大似然 (Maximum Likelihood)



$$\begin{aligned} D &= \{(x_1, y_1), \dots, (x_N, y_N)\} \\ w^*, b^* &= \underset{w, b}{\operatorname{argmax}} \prod_{i=1}^N p(y_i | x_i) = \underset{w, b}{\operatorname{argmax}} \log \left[\prod_{i=1}^N p(y_i | x_i) \right] \\ &= \underset{w, b}{\operatorname{argmax}} \sum_{i=1}^N \log p(y_i | x_i) = \underset{w, b}{\operatorname{argmax}} \sum_{i=1}^N \log \left[\frac{1}{\sqrt{2\pi}\sigma} \exp \left(-\frac{(w^T x_i + b - y_i)^2}{2\sigma^2} \right) \right] \\ &= \underset{w, b}{\operatorname{argmax}} \sum_{i=1}^N \left(-\log(\sqrt{2\pi}\sigma) - \frac{(w^T x_i + b - y_i)^2}{2\sigma^2} \right) \\ &= \underset{w, b}{\operatorname{argmax}} \sum_{i=1}^N -\frac{(w^T x_i + b - y_i)^2}{2\sigma^2} \\ &= \underset{w, b}{\operatorname{argmin}} \sum_{i=1}^N (w^T x_i + b - y_i)^2 \quad \square \end{aligned}$$

$$\max \log p(D) \Leftrightarrow \min \sum_{i=1}^N (w^T x_i + b - y_i)^2$$

高斯误差模型下的最大似然

线性回归的最小二乘

- 与w,b无关的参数忽略--在求导过程中为0

假设有N维向量 $x_1, x_2, \dots, x_N, x_i \in R^n$

观测值Y: $y_1, y_2, \dots, y_N, y_i \in R^n$

定义线性方程: $y_i = w^T x_i, w \in R^n$

拟合误差: $e_i = y_i - w^T x_i$

假设误差符合标准正太分布: $e_i \sim N(0, 1)$

即概率密度函数: $e_i \sim \frac{1}{\sqrt{2\pi}} e^{-\frac{e_i^2}{2}}$

似然函数

$$\begin{aligned} \text{似然函数 } L &= \ln \left[\frac{1}{\sqrt{2\pi}} e^{-\frac{e_1^2}{2}} \frac{1}{\sqrt{2\pi}} e^{-\frac{e_2^2}{2}} \cdots \frac{1}{\sqrt{2\pi}} e^{-\frac{e_N^2}{2}} \right] \\ &= -N \ln \sqrt{2\pi} - \frac{1}{2} (e_1^2 + e_2^2 + \cdots + e_N^2) \end{aligned}$$

https://blog.csdn.net/weixin_42521167

最小化误差

最大化L等价于

最小化 $(e_1^2 + e_2^2 + \cdots + e_N^2)$

$$J = \min (y_1 - w^T x_1)^2 + (y_2 - w^T x_2)^2 + \cdots + (y_N - w^T x_N)^2$$

https://blog.csdn.net/weixin_42521167

求解权重最优解

$$J = \min(y_1 - w^T x_1)^2 + (y_2 - w^T x_2)^2 + \cdots + (y_N - w^T x_N)^2$$
$$\frac{\partial J}{\partial w} = (y_1 - w x_1^T) x_1 + \cdots + (y_N - w x_N^T) x_N = 0$$
$$w \left(\sum_{i=1}^N x_i^T x_i \right) = \sum_{i=1}^N x_i y_i$$
$$w = \left(\sum_{i=1}^N x_i y_i \right) \left(\sum_{i=1}^N x_i^T x_i \right)^{-1}$$

对比之前 $a = (x^T x)^{-1} x^T Y$

最终得到的w和最小二乘估计得到的结果是一致的。

逻辑回归-分类问题:

0-1问题：是否违约，情感分析（开心与否），广告点击率，疾病分析

逻辑回归本身解决的是二分类问题： $p(y=1|x)$ 和 $p(y=0|x)$

建立逻辑回归模型要考虑定义域与值域的匹配问题， y 与 x 的对应关系中， $p(y|x)$ 的取值只可能落在 $(0, 1)$ 里

逻辑函数：

$$y = \frac{1}{1 + e^{-x}}$$

定义域(x): $x \in (-\infty, +\infty)$

值域(y): $y \in (0, 1)$

采用线性回归建模的思想来处理逻辑回归的映射关系：

对于特征向量 x 和二分类标签 y ，我们可以定义如下的条件概率：

$$p(y=1|x,w,b) = \frac{1}{1+e^{-(w^T x+b)}}$$


$$p(y=0|x,w,b) = \frac{e^{-(w^T x+b)}}{1+e^{-(w^T x+b)}}$$

证明逻辑回归是线性分类器：

逻辑回归模型是线性分类器

$$p(y=1|x,w) = \frac{1}{1+e^{-(w^T x+b)}}$$

$$p(y=0|x,w) = \frac{e^{-(w^T x+b)}}{1+e^{-(w^T x+b)}}$$



给定任意点 x ，我们有

$$\frac{1}{1+e^{-(w^T x+b)}} = \frac{e^{-(w^T x+b)}}{1+e^{-(w^T x+b)}}$$

\Leftrightarrow

$$1 = e^{-(w^T x+b)} \quad \left. \begin{array}{l} \log \end{array} \right\}$$

\Leftrightarrow

$$0 = -(w^T x+b)$$

\Leftrightarrow

$$w^T x + b = 0 \Leftarrow \text{线性}$$

+

采用条件独立(conditional independence)的假设，在这个假设的前提下，可以把条件概率 $p(x_1, \dots, x_n | w)$ 分解成 $p(x_1 | w) \dots p(x_n | w)$ ，构造极大似然函数。

目标函数 (Objective Function)

假设我们拥有数据集: $D = \{(x_i, y_i)\}_{i=1}^n$ $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$

而且我们已经定义了:

$$p(y|x, w, b) = p(y = 1|x, w, b)^y [1 - p(y = 1|x, w, b)]^{1-y}$$

我们需要最大化的目标函数为 (也叫做最大似然函数):

$$\hat{w}_{MLE}, \hat{b}_{MLE} = \operatorname{argmax}_{w, b} \prod_{i=1}^n p(y_i | x_i, w, b)$$

将两个条件概率公式合并: 当 $y=1$ 时, 后面那一项不起任何作用也就变成了第一个条件概率; 当 $y=0$ 时, 前面那一项不起作用, 也就等同于第二个条件概率。

目标函数

给定条件概率: $p(y|x, w, b) = p(y = 1|x, w, b)^y [1 - p(y = 1|x, w, b)]^{1-y}$

$$\operatorname{argmin}_{w, b} - \sum_{i=1}^n \log p(y_i | x_i, w, b)$$

$$\begin{aligned} \log(a^x \cdot b^y) &= \log(a^x) + \log(b^y) \\ &= x \cdot \log a + y \cdot \log b \end{aligned}$$

$$\begin{aligned} &= \operatorname{argmin}_{w, b} - \sum_{i=1}^n \log \left[p(y_i=1 | x_i, w, b)^{y_i} \cdot [1 - p(y_i=1 | x_i, w, b)]^{1-y_i} \right] \\ &= \operatorname{argmin}_{w, b} - \sum_{i=1}^n \left[y_i \log p(y_i=1 | x_i, w, b) + (1-y_i) \log [1 - p(y_i=1 | x_i, w, b)] \right] \end{aligned}$$

求解目标函数的最值:

- 导数为0: 对逻辑回归不适用, 导数表达式难以写出
- 迭代方法如梯度下降: 不断更新参数, 与lr参数相关。

梯度下降法:

方法2: 梯度下降法

求使得 $f(w)$ 值最小的参数 w

初始化: w^1

for $t = 1, 2, \dots$:

$$w^{t+1} = w^t - \eta \nabla f(w^t)$$

$$w^* = -\frac{5}{8} = -0.625$$

例子: 求解函数 $f(w) = 4w^2 + 5w + 1$ 的最优解

$$w^1 = 0, \eta = 0.1, f'(w) = 8w + 5$$

$$w^2 = w^1 - 0.1 \cdot (8 \cdot 0 + 5) = 0 - 0.1 \cdot 5 = -0.5$$

$$w^3 = w^2 - 0.1 \cdot (8 \cdot (-0.5) + 5) = -0.5 - 0.1 \cdot 1 = -0.6$$

$$w^4 = w^3 - 0.1 \cdot (8 \cdot (-0.6) + 5) = -0.6 - 0.1 \cdot 0.2 = -0.62$$

$$w^5 = w^4 - 0.1 \cdot (8 \cdot (-0.62) + 5) = -0.62 - 0.1 \cdot 0.04 \approx -0.625$$

对于逻辑函数的求导

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\sigma'(x) = ?$$

$$\sigma'(x) = \frac{(1 \cdot (1 + e^{-x}) - 1 \cdot (1 + e^{-x})')}{(1 + e^{-x})^2} = \frac{e^{-x}}{(1 + e^{-x})^2}$$

$$\begin{aligned} &= \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} = \frac{1}{1 + e^{-x}} \cdot \left[1 - \frac{1}{1 + e^{-x}} \right] \\ &= \sigma(x) \cdot [1 - \sigma(x)] \end{aligned}$$

求解 w 参数:

逻辑回归的梯度下降法—求解w

$$p(y=1|x, w, b) = \frac{1}{1 + e^{-(w^T x + b)}} = \sigma(w^T x + b)$$

$$\text{argmin}_{w, b} - \sum_{i=1}^n y_i \log p(y_i=1|x_i, w, b) + (1-y_i) \log(1-p(y_i=1|x_i, w, b))$$

$$\begin{aligned} \mathcal{L} &= \text{argmin}_{w, b} - \sum_{i=1}^n y_i \log \sigma(w^T x_i + b) + (1-y_i) \log [1 - \sigma(w^T x_i + b)] \\ \left[\frac{\partial \mathcal{L}}{\partial w} \right] &= - \sum_{i=1}^n y_i \cdot \frac{\sigma(w^T x_i + b) [1 - \sigma(w^T x_i + b)] x_i}{\sigma(w^T x_i + b)} + (1-y_i) \cdot \frac{-\sigma(w^T x_i + b) [1 - \sigma(w^T x_i + b)] \cdot x_i}{1 - \sigma(w^T x_i + b)} \\ &= - \sum_{i=1}^n y_i [1 - \sigma(w^T x_i + b)] x_i + (y_i - 1) \sigma(w^T x_i + b) x_i \\ &= \sum_{i=1}^n [\sigma(w^T x_i + b) - y_i] x_i \quad \square \end{aligned}$$

求解b参数:

逻辑回归的梯度下降法—求解b

$$p(y=1|x, w, b) = \frac{1}{1 + e^{-(w^T x + b)}}$$

$$\text{argmin}_{w, b} - \sum_{i=1}^n y_i \log p(y_i=1|x_i, w, b) + (1-y_i) \log(1-p(y_i=1|x_i, w, b))$$

$$\begin{aligned} &= \text{argmin}_{w, b} - \sum_{i=1}^n y_i \log \sigma(w^T x_i + b) + (1-y_i) \log [1 - \sigma(w^T x_i + b)] \\ \left[\frac{\partial \mathcal{L}}{\partial b} \right] &= - \sum_{i=1}^n y_i \cdot \frac{\sigma(w^T x_i + b) [1 - \sigma(w^T x_i + b)]}{\sigma(w^T x_i + b)} + (1-y_i) \cdot \frac{-\sigma(w^T x_i + b) [1 - \sigma(w^T x_i + b)]}{1 - \sigma(w^T x_i + b)} \\ &= \sum_{i=1}^n (\sigma(w^T x_i + b) - y_i) \end{aligned}$$

迭代更新:

$$w' = w - lr * f'(w)$$

$$b' = b - lr * f'(b)$$

$f'(w, b)$ 为损失函数

逻辑回归的梯度下降法

初始化: w^1, b^1

for $t = 1, 2 \dots$

$$w^{t+1} = w^t - \eta_t \sum_{i=1}^n (\sigma(w^T x_i + b) - y_i) x_i$$

$$b^{t+1} = b^t - \eta_t \sum_{i=1}^n (\sigma(w^T x_i + b) - y_i)$$

判断收敛:

- 相邻时间段计算当前的损失函数, 损失函数变化很小或者不变即收敛
- 相邻时间段计算当前参数的值 w, b , 参数值变化很小或者不变即收敛