

1.求交叉熵的反向传播函数

交叉熵损失函数常用于分类问题中，在二分类的问题中，由于只有两种情况1或者0，对应的概率为 $p, 1-p$ 。则表达式为：

$$L = -[y \cdot \log(p) + (1 - y) \cdot \log(1 - p)]$$


y 为样本标签， p 为样本预测为1或者正的概率。那么在多分类中的损失函数为：

$$L = - \sum_{i=1}^n y_i \log(p_i)$$

n 为类别数量。

预测概率 $a_i = p_i = e^{-(w^T x_i + b)} / \sum_k e^{-(w^T x_k + b)}$ ，为softmax函数。那么在神经网络中，将 a_i^l 表示第 l 层第 i 个神经元的输出，令 $z_i^l = -(w^T x_i + b)$ 表示第 l 层第 i 个神经元的输入，即 $l-1$ 层的输出， $\sum_k e^{z_k^l}$ 表示第 l 层所有神经元的输入之和。则


$$a_i^l = e^{z_i^l} / \sum_k e^{z_k^l}$$



<https://blog.csdn.net/abc13526222160>

求什么值：在反向传播中依据微积分中的链式法则，沿着从输出层到输入层的顺序，依次计算并存储目标函数有关神经网络各层的中间变量以及参数的梯度，也就是每一层 z_i 的梯度，即 $\frac{\partial L}{\partial z_i}$ ：

根据复合函数求导法则： $\frac{\partial L}{\partial z_i} = \sum_j (\frac{\partial L_j}{\partial a_j} \cdot \frac{\partial a_j}{\partial z_i})$ ，对于每一层神经元不止一个，所以表示该层神经元下标， $L = L_1 + L_2 + \dots + L_M$ ， M 为神经元个数。



由于 L 包含所有神经元输出，当 $i=j$ 时，每个分量都要对 z_i 求导，此时只需每个对 z_i 求导

$$\begin{aligned} \frac{\partial L_j}{\partial a_j} &= \frac{\partial (-y_j \ln a_j)}{\partial a_j} = -y_j \frac{1}{a_j} \\ \frac{\partial a_j}{\partial z_i} &= \frac{\partial (\frac{e^{z_i}}{\sum_k e^{z_k}})}{\partial z_i} = \frac{e^{z_i} e^{z_k} - (e^{z_i})^2}{(\sum_k e^{z_k})^2} \\ &= \frac{e^{z_i}}{\sum_k e^{z_k}} (1 - \frac{e^{z_i}}{\sum_k e^{z_k}}) \\ &= a_i (1 - a_i) \end{aligned}$$

$$\begin{aligned} \frac{\partial a_j}{\partial z_i} &= \frac{\partial (\frac{e^{z_j}}{\sum_k e^{z_k}})}{\partial z_i} = e^{z_j} \frac{-1}{(\sum_k e^{z_k})^2} \cdot z_i \\ &= -\frac{e^{z_j}}{\sum_k e^{z_k}} \cdot \frac{e^{z_k}}{\sum_k e^{z_k}} = -a_i a_j \end{aligned}$$

$$\begin{aligned}
 \text{则 } \frac{\partial L}{\partial z_i} &= \sum_j \left(\frac{\partial L_j}{\partial a_j} \cdot \frac{\partial a_j}{\partial z_i} \right) = \sum_{j \neq i} \left(\frac{\partial L_j}{\partial a_j} \cdot \frac{\partial a_j}{\partial z_i} \right) + \sum_{j=i} \left(\frac{\partial L_j}{\partial a_j} \cdot \frac{\partial a_j}{\partial z_i} \right) \\
 &= \sum_{j \neq i} -\frac{y_j}{a_j} \cdot (-a_j a_j) + \left(-\frac{y_i}{a_i} \right) \cdot a_i (1-a_i) \\
 &= \sum_{j \neq i} y_j a_i + y_i (a_i - 1) \\
 &= \sum_{j \neq i} y_j a_i + y_i a_i - y_i \\
 &= \sum_j a_i y_j - y_i
 \end{aligned}$$

而打2i, 在分类中只有一个类的, 其它全为0, 因此 $\frac{\partial L}{\partial z_i} = a_i - y_i$

2. 证明逻辑斯蒂是凸优化问题

逻辑函数的目标函数为 $L = -\sum_i^n [y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)]$

, 其中 y_i 为样本标签取0或1, p_i 为对应样本标签的概率, $p_i = 1 / (1 + e^{-(w^T x_i + b)})$, 将参数 (w, b) 的 b 融入到 w 中, 则 $w = (w_0, w_1, w_2, \dots, w_n)$, n 为样本大小, w_0 即为 b 的值, 则 $x_i = (1, x_{i1}, x_{i2}, \dots, x_{in})$, 则 $p_i = 1 / (1 + e^{-w^T x_i})$

若要证明目标函数为凸函数, 则对 w 二次求导后, 二阶导函数大于0即可。

证明: $\frac{1}{1+e^{-x}} \quad \delta'(x) = \frac{0 - (-1) \cdot e^{-x}}{(1+e^{-x})^2} = \frac{e^{-x}}{(1+e^{-x})^2} = \delta(x) \cdot (1 - \delta(x))$



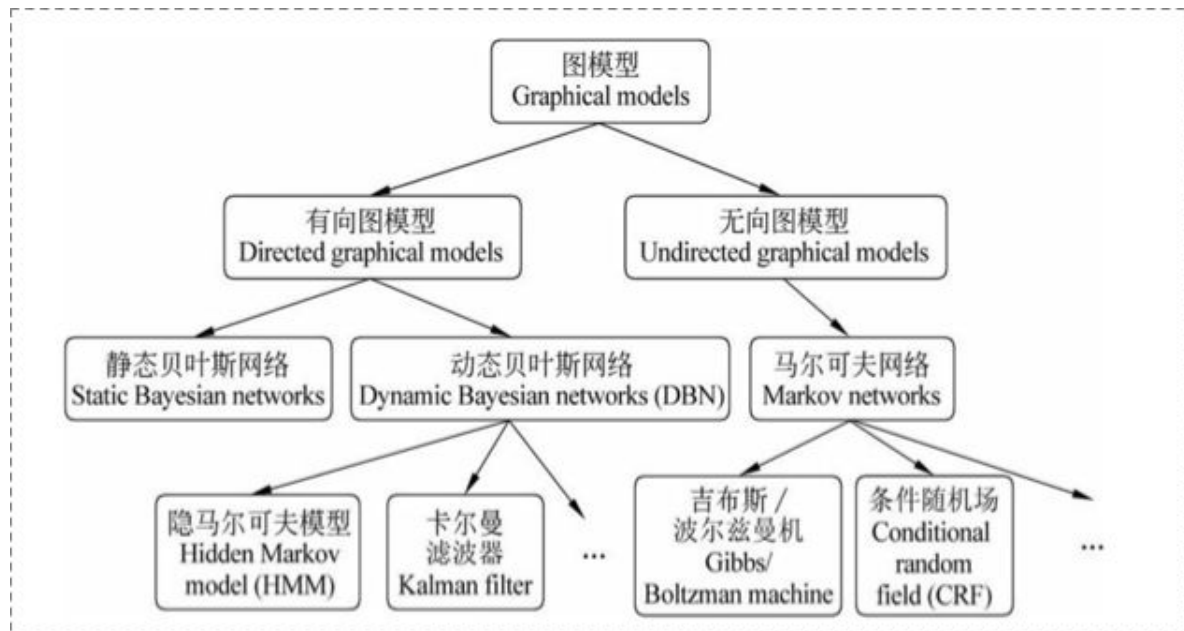
$$\begin{aligned}
 \frac{\partial L}{\partial w} &= \frac{\partial \left[-\sum_{i=1}^n y_i \log \delta(w^T x_i) + (1 - y_i) \log [1 - \delta(w^T x_i)] \right]}{\partial w} \\
 &= -\sum_{i=1}^n y_i \cdot \frac{1}{\delta(w^T x_i)} \cdot \delta(w^T x_i) \cdot [1 - \delta(w^T x_i)] \cdot x_i + (1 - y_i) \cdot \frac{-\delta(w^T x_i) [1 - \delta(w^T x_i)] \cdot x_i}{1 - \delta(w^T x_i)} \\
 &= -\sum_{i=1}^n y_i [1 - \delta(w^T x_i)] x_i + (y_i - 1) \delta(w^T x_i) x_i \\
 &= -\sum_{i=1}^n x_i y_i - x_i y_i \delta(w^T x_i) + x_i y_i \delta(w^T x_i) - x_i \delta(w^T x_i) \\
 &= -\sum_{i=1}^n x_i [y_i - \delta(w^T x_i)]
 \end{aligned}$$

→ 去掉 δw 无差项

$$\begin{aligned}
 \frac{\partial^2 L}{\partial w^2} &= \frac{\partial \left(\sum_{i=1}^n \delta(w^T x_i) x_i \right)}{\partial w} = x_i^2 \cdot \delta(w^T x_i) \cdot [1 - \delta(w^T x_i)] \\
 \because 0 < \delta(w^T x_i) = 1 / (1 + e^{-w^T x_i}) < 1, \text{ 而 } x_i^2 > 0 \quad \therefore \frac{\partial^2 L}{\partial w^2} > 0, \text{ 则 logistic 为凸优化问题.}
 \end{aligned}$$

3.画出逻辑回归的概率图模型，并写出各点、边的势函数

在概率图模型中，根据生成模型、判别模型来分类，一般有向图为生成模型，无向图为判别模型



逻辑回归中, $p(y=k|x,w) = \frac{e^{-(w^T x_k + b)}}{\sum_{i=1}^K e^{-(w^T x_i + b)}}$

将 b 整合到 w 中, $\delta(x) = e^{-w^T x}$

$p(y=k|x,w) = \frac{e^{-\delta(x_k)}}{\sum_{i=1}^K e^{-\delta(x_i)}}$